TRABAJO PRÁCTICO N.º 2 — ANÁLISIS DE DATOS CON SAKILA

Actividad 5 — Informe de conclusiones

Variante 5: Rendimiento comercial por tienda y por empleado
Integrantes: Bugnoni, Magalí y Lening, Dalma
Materia: Seminario de Actualización

1. Introducción y pregunta de negocio

El presente trabajo tiene como objetivo analizar el rendimiento comercial de las tiendas y los empleados de la base de datos Sakila, previamente migrada desde MySQL hacia SQL Server.
La pregunta de negocio correspondiente a la variante asignada fue:
¿Cómo se reparte el negocio entre las tiendas y entre quienes atienden? ¿Las diferencias son de volumen o de comportamiento de compra?
Para responderla, se analizaron los ingresos totales, la cantidad de operaciones, el ticket promedio y la participación porcentual de cada empleado y tienda sobre la facturación.
El desarrollo se organizó en cinco actividades: preparación y reconciliación de datos, extracción mediante SQL, diagnóstico de calidad, análisis y visualización, y construcción de un proceso ETL.
Durante las actividades 0 y 1, las integrantes del equipo se reunieron presencialmente para organizar la estructura del proyecto, definir cómo abordar la consigna y comenzar su desarrollo. Posteriormente, continuamos trabajando conjuntamente mediante Discord, compartiendo avances, revisando resultados y resolviendo las dificultades técnicas que fueron apareciendo.
Este enfoque nos permitió desarrollar el análisis de manera progresiva, comprobando los resultados de cada etapa antes de avanzar a la siguiente.

2. Metodología y decisiones de diseño

2.1. Herramientas y conexión

Se utilizó SQL Server, ejecutado mediante Docker, Python 3.12, pandas, Jupyter Notebook y Visual Studio Code.
Para conectar Python con SQL Server se eligió el controlador mssql-python, junto con la biblioteca python-dotenv para administrar la configuración de conexión mediante variables de entorno.
Las credenciales se almacenaron en un archivo .env, separado del código fuente y excluido del repositorio de GitHub.
Se creó el archivo esquema.py, que contiene un diccionario de equivalencias entre los nombres canónicos de Sakila y los nombres utilizados en la base migrada. Por ejemplo, la tabla payment corresponde a pago.
Se tomó esta decisión para centralizar las equivalencias y facilitar la adaptación del proyecto a otras versiones de la base de datos.

2.2. Distribución del procesamiento entre SQL y Python

Se decidió utilizar SQL Server para realizar las uniones entre tablas, las agregaciones principales y los cálculos de indicadores comerciales.
Esta distribución permitió reducir la cantidad de información transferida hacia Python.

Para calcular las participaciones porcentuales se utilizaron funciones de ventana de T-SQL, especialmente:
SUM(...) OVER (PARTITION BY ...)
En pandas se realizaron cálculos equivalentes mediante groupby() y transform().
Los resultados obtenidos con ambas herramientas fueron comparados para verificar su consistencia. También se midieron tiempos de ejecución, considerando que las mediciones no representan condiciones idénticas: SQL Server incluye la consulta y transferencia de datos, mientras que pandas trabaja con información previamente cargada en memoria.
Python se utilizó principalmente para el perfilado de datos, las validaciones complementarias, las visualizaciones y la automatización del proceso ETL.

2.3. Criterios de limpieza

Antes de interpretar los indicadores comerciales se realizaron controles sobre valores faltantes, duplicados, montos negativos, fechas futuras y relaciones entre pagos, empleados, clientes y alquileres.
Se decidió no eliminar ni modificar registros cuando no existieran evidencias suficientes de que fueran incorrectos.
En particular, los pagos identificados como atípicos mediante el método del rango intercuartílico (IQR) se conservaron, debido a que no se detectaron inconsistencias en sus relaciones con los alquileres y clientes.
Esta decisión evitó alterar injustificadamente los ingresos totales y los tickets promedio.

2.4. Estrategia de carga del ETL

Se desarrolló el archivo actividad4_etl.py, encargado de extraer información desde SQL Server e integrarla con un segundo origen: el archivo metas_comerciales.csv.
Este archivo contiene metas simuladas de $35.000 para cada tienda, utilizadas exclusivamente con fines académicos.
La integración se realizó mediante merge() de pandas.
Para almacenar los resultados se utilizó la tabla dbo.TP2_RendimientoComercial.
Se eligió una estrategia de reemplazo completo mediante DELETE + INSERT dentro de una transacción, porque el volumen de resultados era reducido y no era necesario conservar versiones históricas de los indicadores.
La transacción permite confirmar la carga cuando finaliza correctamente o revertirla mediante ROLLBACK si ocurre un error.
El ETL se ejecutó en varias oportunidades y la tabla de destino mantuvo dos registros, sin acumulación de filas duplicadas.

3. Diagnóstico de calidad de datos

El análisis se realizó sobre 16.044 operaciones de pago, correspondientes al período comprendido entre el 24 de mayo de 2005 y el 14 de febrero de 2006.
Como parte de la preparación del proyecto, también se reconciliaron las 16 tablas de Sakila entre el origen y SQL Server. Todas presentaron diferencias de cero registros.
La tabla film_text requirió una verificación particular, ya que sus registros se generan mediante un trigger en el esquema original. Se comprobó que contenía 1.000 registros tanto en MySQL como en su tabla equivalente de SQL Server.
En el análisis de calidad de los pagos se obtuvieron los siguientes resultados:

Control realizado	Resultado
Pagos analizados	16.044
Valores faltantes	0
Pagos duplicados	0
Pagos sin empleado válido	0
Empleados sin operaciones	0
Montos negativos	0
Fechas futuras	0
Pagos atípicos por IQR	857
Clientes con pagos procesados en ambas tiendas	599

Los 857 pagos atípicos representan aproximadamente el 5,34 % del conjunto y superan el límite superior de $7,99 establecido mediante IQR.
De ellos, 855 presentan importes terminados en ,99, lo que sugiere un patrón compatible con precios comerciales. También se verificó que todos los pagos atípicos estuvieran relacionados con alquileres existentes y clientes coincidentes.
Por este motivo, se decidió conservarlos.
Los controles realizados respaldan la utilización de los datos para calcular indicadores comerciales. Sin embargo, la ausencia de errores detectados no demuestra que todos los importes sean correctos ni que la información esté completa respecto de la actividad comercial real.
Además, la identificación de 599 clientes con pagos procesados por empleados de ambas tiendas impide interpretar automáticamente cada operación como una compra realizada físicamente en la tienda asociada al empleado.

4. Resultados y hallazgos comerciales

Los indicadores generales obtenidos fueron los siguientes:

Indicador	Tienda 1	Tienda 2
Empleado	Mike Hillyer	Jon Stephens
Ingresos totales	$33.482,50	$33.924,06
Cantidad de operaciones	8.054	7.990
Ticket promedio	$4,16	$4,25
Participación en el negocio	49,67 %	50,33 %
Participación del empleado en su tienda	100 %	100 %



Ingreso total del negocio: $67.406,56

Hallazgo 1. La participación de los empleados es del 100 % en cada tienda

El gráfico de barras apiladas al 100 % muestra que Mike Hillyer representa la totalidad de los ingresos asociados a la tienda 1, mientras que Jon Stephens representa la totalidad de los ingresos asociados a la tienda 2.
Esto ocurre porque el conjunto analizado contiene un solo empleado registrado por tienda. Por lo tanto, aunque se cumple con el cálculo de participación porcentual solicitado, este indicador no permite comparar la distribución de ingresos entre varios empleados de una misma sucursal.
Los gráficos 1,2 y 3 se encuentran adjuntos en el repositorio de github y la bitácora hallazgos.
Gráfico 1. Participación de ingresos por empleado y tienda.
Interpretación comercial: para evaluar la productividad individual sería necesario incorporar otras variables, como las horas trabajadas, la cantidad de clientes atendidos y la distribución de tareas.

Hallazgo 2. La tienda 2 obtiene un ticket promedio superior con menos operaciones

La tienda 1 registró 8.054 operaciones y un ingreso total de $33.482,50.
La tienda 2 registró 7.990 operaciones y un ingreso total de $33.924,06.
Aunque la tienda 2 procesó 64 operaciones menos, obtuvo $441,56 más de ingresos.
El ticket promedio fue de aproximadamente $4,16 en la tienda 1 y $4,25 en la tienda 2.
Gráfico 2. Ticket promedio por tienda.
Interpretación comercial: la diferencia de ingresos no se explica únicamente por la cantidad de operaciones. El importe promedio de los pagos también influye en la facturación.
Sin embargo, el mayor ticket promedio no demuestra por sí solo que una tienda o su empleado trabajen mejor. Sería necesario investigar las tarifas, los tipos de alquiler, las características de los clientes y otros factores que podrían explicar la diferencia.

Hallazgo 3. Julio de 2005 presenta la mayor facturación mensual registrada

El análisis temporal permitió identificar que julio de 2005 fue el mes con mayores ingresos registrados en ambas tiendas.
Los valores obtenidos fueron:

- Tienda 1: $13.998,56.
- Tienda 2: $14.370,35.

La tienda 2 presentó una facturación ligeramente superior durante ese mes.
Gráfico 3. Evolución mensual de ingresos por tienda.
Interpretación comercial: los ingresos no se distribuyen uniformemente entre los meses disponibles. Sin embargo, existen períodos sin registros, por lo que no es posible concluir que julio represente un pico estacional habitual.
Antes de utilizar esta información para planificar recursos o establecer metas mensuales sería necesario verificar la cobertura temporal de los datos y analizar períodos adicionales.

5. Limitaciones del análisis

Si bien el proyecto permitió obtener indicadores estables y responder parcialmente la pregunta de negocio, es importante reconocer las siguientes limitaciones.

Cantidad de empleados. El conjunto contiene un solo empleado por tienda. En consecuencia, no es posible comparar empleados dentro de una misma sucursal ni estudiar cómo se distribuye el trabajo entre varios integrantes del personal.
Facturación y productividad. Una tienda que factura más no necesariamente trabaja mejor. Para evaluar eficiencia o productividad sería necesario considerar variables como horas trabajadas, costos operativos,características de las operaciones, etc.
Comportamiento de compra. El ticket promedio permite identificar diferencias en los importes de las operaciones, pero no explica sus causas. No se analizaron en profundidad las preferencias de los clientes, los productos alquilados ni las tarifas aplicadas.
Cobertura temporal. La base contiene información histórica y meses sin registros. Por lo tanto, no se pueden establecer tendencias actuales ni afirmar que las diferencias mensuales respondan a fenómenos estacionales.
Relación entre clientes y tiendas. Se identificaron 599 clientes con pagos procesados por empleados de ambas tiendas. Esto requiere precaución al interpretar la pertenencia de cada operación a una sucursal y no permite afirmar que todos esos clientes hayan visitado físicamente ambas tiendas.
Calidad de los importes. Aunque los controles de integridad fueron satisfactorios, no se realizó una auditoría completa de los precios cobrados frente a todas las reglas tarifarias posibles.
Metas comerciales simuladas. Las metas incorporadas mediante el archivo CSV fueron creadas para demostrar la integración de dos fuentes en el ETL. No representan objetivos reales de Sakila y, por lo tanto, no deben utilizarse para evaluar el desempeño comercial real.
Estas limitaciones indican que los resultados son adecuados para describir el comportamiento del conjunto de datos analizado, pero no para establecer conclusiones definitivas sobre eficiencia laboral, rentabilidad o desempeño comercial general.

6. Dificultades encontradas y soluciones implementadas

Durante el desarrollo del proyecto surgieron distintas dificultades técnicas que requirieron investigación, pruebas y trabajo conjunto.

Conexión entre Python y SQL Server

Una de las primeras dificultades fue establecer la comunicación entre Python y SQL Server, ejecutado mediante Docker.
Para resolverla se configuró el controlador mssql-python, se organizaron las variables de conexión mediante .env y se verificó la disponibilidad de las bibliotecas necesarias en macOS.
También fue necesario configurar DYLD_LIBRARY_PATH para permitir la carga de las bibliotecas requeridas por el controlador.

Diferencias entre scripts y notebooks

Al comenzar la Actividad 1 aparecieron nuevamente problemas de conexión, aunque los programas de la Actividad 0 ya funcionaban.
Se identificó que Jupyter Notebook utiliza un kernel propio, que no necesariamente coincide con el entorno virtual empleado para ejecutar los scripts.
La solución consistió en revisar el intérprete seleccionado en Visual Studio Code, configurar correctamente el kernel y comprobar nuevamente la conexión.

Diferencias entre los nombres de las tablas

La migración de Sakila a SQL Server utilizaba nombres en español, mientras que la consigna hacía referencia a los nombres originales en inglés.

Para resolver esta dificultad se implementó el diccionario centralizado en esquema.py y se desarrolló una validación contra INFORMATION_SCHEMA.COLUMNS.
La comprobación no detectó columnas faltantes.

Interpretación de los pagos atípicos
El método IQR identificó 857 pagos atípicos. Sin embargo, eliminarlos directamente habría alterado los indicadores comerciales.
Se realizaron verificaciones complementarias sobre las relaciones con alquileres y clientes, y se decidió conservar los registros al no encontrar evidencias suficientes de errores.
Validación de resultados y ejecución del ETL

Para comprobar los indicadores se compararon cálculos realizados en SQL Server y pandas, obteniendo resultados coincidentes.
En el ETL se eligió una carga transaccional de reemplazo completo. Se realizaron ejecuciones consecutivas y se comprobó que la tabla de destino continuaba conteniendo dos registros, sin acumulación de duplicados.

Organización del trabajo en equipo

La coordinación también formó parte del desarrollo. Inicialmente, nos reunimos presencialmente para organizar las actividades 0 y 1, establecer la estructura del proyecto y definir la metodología de trabajo.
En las actividades posteriores continuamos trabajando conjuntamente mediante Discord, lo que permitió mantener la comunicación, revisar el código, contrastar resultados y resolver las dificultades a medida que surgían.
Esta modalidad facilitó la continuidad del proyecto.

7. Conclusión general

El desarrollo del Trabajo Práctico 2 permitió integrar conocimientos de bases de datos, programación en Python, análisis de datos, control de calidad, visualización y procesos ETL.
A partir de 16.044 operaciones de pago se obtuvo una facturación total de $67.406,56, distribuida de manera similar entre las dos tiendas.
La tienda 2 presentó ingresos y ticket promedio ligeramente superiores, mientras que la tienda 1 registró una mayor cantidad de operaciones. Esto demuestra que las diferencias de facturación no dependen exclusivamente del volumen de pagos, sino también del importe promedio de cada operación.
El análisis permitió responder la pregunta de negocio desde una perspectiva descriptiva, aunque no resultó suficiente para determinar cuál tienda o empleado presenta mayor productividad.
Los controles de calidad, las comparaciones entre SQL Server y pandas y las verificaciones del ETL aportaron consistencia técnica a los resultados.
Finalmente, el proyecto permitió comprender que analizar datos no consiste solamente en calcular indicadores, sino también en verificar su calidad, interpretar sus resultados dentro del contexto disponible y reconocer las limitaciones antes de formular conclusiones comerciales.